

# MODELE Z INTERAKCJAMI I WIELOMIANAMI

EKONOMETRIA WNE

Sebastian Zalas

University of Warsaw

[s.zalas@uw.edu.pl](mailto:s.zalas@uw.edu.pl)

# NIELINIOWOŚĆ W LINOWYM MODELU?


## ► TAK, a w jaki sposób?:

- umieszczenie wielomianu zmiennej objaśniającej
- interakcje

## ► Przykład: **TestScore** vs **Income**, **STratio**

- dane **CASchools** - dostępne w pakiecie **AER**
- **TestScore** - łączny wynik testu z matematyki i czytania; średnia w dystrykcie
- **Income** - średni dochód w dystrykcie
- **STratio** - stosunek liczby nauczycieli do liczby uczniów

# WYNIK TESTU VS DOCHÓD



Wyraźnie relacja pomiędzy TestScore oraz Income jest nieliniowa

# MODEL Z WIELOMIANEM $x$

- Przybliżenie  $y$  za pomocą wielomianu  $x$ :

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \beta_3 x_1^3 + \dots + \beta_k x_1^k + \varepsilon$$

- model nadal jest linowy w stosunku do **parametrów** (*linear in parameters*), model szacujemy korzystając z MNK
- parametry takiego modelu są trudniejsze do interpretacji, ale możliwe  
⇒ efekt cząstkowy

# MODEL Z WIELOMIANEM $x$

- Szacujemy relację między *TestScore* i *Income* (średni dochód w dystrykcie per capita)


- oszacowanie modelu z kwadratem dochodu

$$TestScore = 607.302 + 3.85099Income - 0.04231Income^2 + \varepsilon$$

- oszacowanie modelu z sześciannym dochodu


$$TestScore = 600.079 + 5.018677Income - 0.09580521Income^2 \\ + 0.0006854851Income^3 + \varepsilon$$

# MODEL $z\ x, x^2$



Model z kwadratem zm. zależnej jest lepiej dopasowany do danych

# MODEL $Z$ $x$ , $x^2$ ORAZ $x^3$



Wielomian 3. stopnia nie poprawia sytuacji...

# MODEL Z WIELOMIANEM $x$

- Policz zmiany (dla modelu z kwadratem):

$$\Delta y = \beta_1 \Delta x_1 + \beta_2 \Delta x_1^2$$

- W przybliżeniu

$$\Delta y \approx \beta_1 + 2\beta_2 x_1$$

- równoważność efektu cząstkowego - pochodna po  $x_1$



# MODEL Z WIELOMIANEM X

- Przykład: model z kwadratem dochodu

$$\widehat{\Delta TestScore}_i = 3.85099 - 2 \times 0.04231 Income_i$$

- dla zmiany dochodu o 1 tys. \$ pc., przy dochodzie pc. wynoszącym 10 tys. \$

$$\begin{aligned}\widehat{\Delta TestScore}_i &= 3.85099 - 2 \times 0.04231 \times 10 \\ &= 3.005\end{aligned}$$

- Zmiana dochodu o 1 tys. \$ pc. przy dochodzie pc. wynoszącym 10 tys. \$, jest związana ze wzrostem wyniku testu średnio o 3.005 punktu (w przybliżeniu)

# MODEL Z WIELOMIANEM Z $x$


- Interpretacja dokonywana w okolicy danego punktu
- Możemy policzyć zmiany wartości dopasowanych dla wybranych, konkretnych przedziałów

$\Delta Income$ o 1 tys. \$ per capita	$\Delta TestScore$
z 5 na 6 tys. pc	3.3856
z 10 na 11 tys. pc	2.9625
z 25 na 26 tys. pc	1.6933
z 45 na 46 tys. pc	0.0009

# MODEL Z WIELOMIANEM $x$

- ▶ Aby zinterpretować oszacowania:
  - zrób wykres
  - oblicz przewidywane  $\frac{\Delta y}{\Delta x}$  dla różnych wartości  $x$ .
- ▶ Sposoby wyboru stopnia wielomianu  $k$ : sprawdź wrażliwość oszacowań w różnych wariantach, osąd własny, a także korzystamy ze statystyk  $t$  oraz  $F$  (w przyszłości)
- ▶ Im wyższy będzie stopień wielomianu, tym bardziej model stanie się podatny na odstające obserwacje

# CZY DOSTRZEGAMY TU NIELINIOWOŚĆ?



Na pierwszy rzut oka, relacja między Test Score a Student-Teacher ratio nie wydaje się nieliniowa...

# INTERAKCJE

- ▶ Przyjrzyjmy się modelowi:

$$TestScore = \beta_0 + \beta_1 SRatio + \varepsilon$$

- *TestScore* - średni wyniku testu uczniów w Kalifornii w danym dystrykcie
  - *SRatio* - stosunek liczby nauczycieli do liczby uczniów
- ▶ Zwykle mniej uczniów na jednego nauczyciela, oznacza bardziej indywidualne podejście  $\Rightarrow \uparrow TestScore$
- ▶ Ta zależność (reprezentowna przez  $\beta_1$ ) zależy także od innych czynników

# INTERAKCJE

- ▶ Jakich? Kontekst Kalifornii: ile uczniów zna j. angielski? Przez imigrację z Meksyku te odsetki różnią się między dystryktami
- ▶  $\frac{\Delta \text{TestScore}}{\Delta \text{Stratio}}$  może różnić się w zależności od procenta uczniów uczących się angielskiego, *PEL*
- ▶ Bardziej ogólnie  $\frac{\Delta Y}{\Delta X_1}$  może zależeć od  $X_2$ . Jak modelować takie interakcje?
  - zmienne binarne vs ciągłe

# INTERAKCJE - ZMIENNE BINARNE

- Model ze zmiennymi binarnymi  $D_1, D_2$

$$y = \beta_0 + \beta_1 D_1 + \beta_2 D_2 + \varepsilon$$

- $\beta_1$

- mierzy efekt zmiany z  $D_1 = 0$  na  $D_1 = 1$
- w takiej specyfikacji **ten efekt jest niezależny od wartości  $D_2$**

- Aby zbadać łączną zależność między  $D_1$  i  $D_2$  a  $y$ , musimy uwzględnić **interakcję**, czyli  $D_1 \times D_2$ :

$$y = \beta_0 + \beta_1 D_1 + \beta_2 D_2 + \beta_3 (D_1 \times D_2) + \varepsilon$$

# INTERAKCJE - ZMIENNE BINARNE - INTERPRETACJA

- Intuicja: porównaj przypadki:

$$y = \beta_0 + \beta_1 D_1 + \beta_2 D_2 + \beta_3 D_1 \times \beta_2 D_2 + \varepsilon$$

- Ustalamy wartości  $D_2$ , zmieniamy  $D_1$ :

$$\mathbb{E}(y|D_1 = 0, D_2 = d_2) = \beta_0 + \beta_2 d_2 \quad (1)$$

$$\mathbb{E}(y|D_1 = 1, D_2 = d_2) = \beta_0 + \beta_1 + \beta_2 d_2 + \beta_3 d_2 \quad (2)$$

odejmijmy (2) - (1) :

$$\mathbb{E}(y_i|D_{1,i} = 1, D_{2,i} = d_2) - \mathbb{E}(y_i|D_{1,i} = 0, D_{2,i} = d_2) = \beta_1 + \beta_3 d_2$$

- to jak  $D_1$  wpływa na  $y$  zależy od  $d_2$  (wartość zm.  $D_2$ ).  $\beta_3$  mierzy wpływ zmiany  $D_1$  gdy  $D_2 = 1$



# INTERAKCJE - ZMIENNE BINARNE - PRZYKŁAD

► Zależność *TestScore*, *STratio*; *HEL* oraz *HSTr*

- *HEL* = 1 jeżeli odsetek uczących się angielskiego  $\geq 10$ ; 0 wpp.
- *HSTr* = 1 jeżeli *STratio*  $\geq 20$ , 0 wpp.

► Oszacowanie:

$$\text{TestScore} = 664.1 - 18.2HEL - 1.9HSTr - 3.5(HSTr \times HEL)$$

► Spróbujmy zinterpretować wyniki

# INTERAKCJE - ZMIENNE BINARNE - PRZYKŁAD

- ▶ gdy  $HEL = 0$

$$\mathbb{E}[TestScore|HEL = 0, HSTR = 0] = 664.1$$

$$\mathbb{E}[TestScore|HEL = 0, HSTR = 1] = 664.1 - 1.9 \times 1$$

gdy odsetek uczących się angielskiego jest niski, zwiększenie stosunku l. uczniów do nauczycieli zmniejszyło średnio wynik o 1.9

- ▶ gdy  $HEL = 1$

$$\mathbb{E}[TestScore|HEL = 1, HSTR = 0] = 664.1 - 18.2$$

$$\mathbb{E}[TestScore|HEL = 1, HSTR = 1] = 664.1 - 18.2 - 1.9 - 3.5$$

- ▶ Zmniejszenie liczby uczniów do nauczycieli ma silniejszy związek z wynikiem testu, gdy procent uczących się angielskiego jest duży

# INTERAKCJA ZM. BINARNEJ I CIĄGŁEJ

- Model z interakcją  $x$  (zm. ciągłej) oraz  $D$  (zm. binarna)

$$y = \beta_0 + \beta_1 D + \beta_2 x + \beta_3 D \times x + \varepsilon$$

- Stosując interakcję mamy dwie zagnieżdżone regresje:

- przypadek z  $D_i = 0$

$$y_i = \beta_0 + \beta_2 x_i + u_i$$

- przypadek z  $D = 1$

$$y_i = (\beta_0 + \beta_1) + (\beta_2 + \beta_3)x + \varepsilon$$

- czy relacja między  $y \sim x$  zależy od  $D$ ?

# INTERAKCJA ZM. BINARNEJ I CIĄGŁEJ

- Co mierzy  $\beta_3$ ?

$$y = \beta_0 + \beta_1 D + \beta_2 x + \beta_3 D \times x + \varepsilon$$

- Ustalmy  $D$ , zmieńmy  $x$

$$\Delta y = \beta_2 \Delta x + \beta_3 D \Delta x$$

$$\frac{\Delta y}{\Delta x} = \beta_2 + \beta_3 D$$

- Co mierzy  $\beta_3$ : różnicę nachylenia  $y \sim x$  przy uwzględnieniu  $D$

# INTERAKCJA ZM. BINARNEJ I CIĄGŁEJ - PRZYKŁAD

- Zależność *TestScore*, *STratio* i *HEL* (*HEL* = 1 jeżeli odsetek uczących się angielskiego  $\geq 10$ )

$$\text{TestScore} = 682.2 - 0.97\text{STratio} + 5.6\text{HEL} - 1.28(\text{STratio} \times \text{HEL})$$

- Spójrzmy na dwa przypadki:

- gdy *HEL* = 0:  $\text{TestScore} = 682.2 - 0.97\text{STratio}$
- gdy *HEL* = 1:

$$\text{TestScore} = 682.2 - 0.97\text{STratio} + 5.6 - 1.28\text{STratio} = 687.8 - 2.25\text{STratio}$$

- Obniżenie liczby uczniów przypadających na jednego nauczyciela ma o 1.28 silniejszy wpływ na wyniki uczniów, gdy udział uczniów uczących się angielskiego jest duży.

Pytania? Wątpliwości?  
Dziękuję!

**e:** [s.zalas@uw.edu.pl](mailto:s.zalas@uw.edu.pl)