

TESTOWANIE HIPOTEZ

EKONOMETRIA WNE

Sebastian Zalas

University of Warsaw

s.zalas@uw.edu.pl

KLASYCZNY MODEL REGRESJI LINIOWEJ

1. $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ - model jest liniowy
2. Zmienne losowe $\{(y_1, x_1), \dots, (y_i, x_i), \dots, (y_n, x_n)\}$ są niezależne oraz wylosowane z tego samego rozkładu (*independently and identically distributed - iid.*)
3. $\text{rz}[\mathbf{X}_{n \times k}] = k$ - rząd kolumnowy \mathbf{X} jest pełny
4. $\mathbb{E}[\boldsymbol{\varepsilon}|\mathbf{X}] = \mathbf{0}$ - wartość oczekiwana składnika losowego jest równa 0
5. $\mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'|\mathbf{X}] = \mathbf{I}\sigma^2$ - sferyczność wariancji
6. $\boldsymbol{\varepsilon}|\mathbf{X} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}\sigma^2)$ składnik losowy ma rozkład normalny

ROZKŁAD ESTYMATORA MNK

- ▶ w KMRL mamy następujące założenie:

$$\varepsilon \mid \mathbf{X} \sim \mathcal{N}(\mathbf{0}, I\sigma^2) \quad (1)$$

na jego podstawie wyprowadzimy rozkład estymatora MNK.

- ▶ Przepiszemy (1) założenie korzystając z $\hat{\beta} - \beta = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\varepsilon$

$$\begin{aligned}\hat{\beta} - \beta \mid \mathbf{X} &\sim (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathcal{N}(\mathbf{0}, I\sigma^2) \\ &\sim \mathcal{N}(\mathbf{0}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}) \\ &= \mathcal{N}(\mathbf{0}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})\end{aligned}$$

- ▶ co oznacza, że:

$$\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}) \quad (2)$$

- Możemy znormalizować (2):

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\sigma^2[(\mathbf{X}'\mathbf{X})^{-1}]_{jj}}} \sim \mathcal{N}(0, 1)$$

- Nie obserwujemy σ^2 ; należy skorzystać z oszacowania:

$$t = \frac{\hat{\beta}_j - \beta_j}{\sqrt{s^2[(\mathbf{X}'\mathbf{X})^{-1}]_{jj}}} \sim t_{n-k-1}$$

- Wtedy statystyka t ma rozkład t-studenta z $n - k - 1$ stopniami swobody

TEST T

- ▶ Mamy prosty model:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

- ▶ korzystając ze statystyki T możemy zweryfikować hipotezę o β_1 :

$$H_0 : \beta_1 = d$$

$$H_1 : \beta_1 \neq d$$

- ▶ Przy założeniu, że hipoteza zerowa jest prawdziwa, obliczamy wartość **statystyki testowej**:

$$t = \frac{\hat{\beta} - d}{se(\hat{\beta})} \sim t(n - k - 1)$$

TESTOWANIE HIPOTEZY

- ▶ następnie ustalamy **poziom istotności** α ; standardowo przyjmuje się $\alpha = 0.05$
- ▶ znajdujemy **wartości krytyczne**: $t_{\frac{\alpha}{2}, n-k-1}^*$ oraz $t_{1-\frac{\alpha}{2}, n-k-1}^*$
- ▶ przyjmujemy hipotezę zerową jako prawdziwą, jeżeli statystyka testowa znajduje się pomiędzy wartościami krytycznymi. W przeciwnym przypadku, odrzucamy hipotezę zerową na rzecz alternatywnej.
- ▶ alternatywnie, jeżeli $p - value < \alpha$ to odrzucamy hipotezę zerową

TESTOWANIE ISTOTNOŚCI

- Sprowadza się do przetestowania hipotezy w postaci:

$$H_0 : \beta_1 = 0$$

$$H_1 : \beta_1 \neq 0$$

- obliczmy wartość statystyki t :

$$T = \frac{\hat{\beta}_k}{\text{se}(\hat{\beta})} \sim t(n - k - 1)$$

- znajdujemy **wartości krytyczne**: $t_{\frac{\alpha}{2}, n-k-1}^*$ oraz $t_{1-\frac{\alpha}{2}, n-k-1}^*$, bądź p – *value* i przeprowadzamy wnioskowanie.

ROZKŁAD t - STUDENTA

Obszary akceptacji i odrzucenia H_0 w teście t z obustronną H_1



PRZEDZIAŁ UFNOŚCI

- Estymator przedziałowy \hat{C} taki, że będzie on zawierał prawdziwy parametr β_1 z ustalonym prawdopodobieństwem równym $1 - \alpha$.

$$\mathbb{P}(\beta \in \hat{C}) = 1 - \alpha$$

- Jest to prawdopodobieństwo, że **losowy** przedział \hat{C} zawiera prawdziwy, **ustalony** parametr β_1
- Możemy skonstruować przedział ufności w oparciu o statystykę T i odchylenie standardowe β :

$$\mathbb{P}\left(t_{\frac{\alpha}{2}, n-k-1}^* \leq t \leq t_{1-\frac{\alpha}{2}, n-k-1}^*\right) = 1 - \alpha$$

$$\mathbb{P}\left(t_{\frac{\alpha}{2}, n-k-1}^* \leq \frac{\beta_1 - \hat{\beta}_1}{se(\hat{\beta}_1)} \leq t_{1-\frac{\alpha}{2}, n-k-1}^*\right) = 1 - \alpha$$

PRZEDZIAŁY UFNOŚCI

- Po przekształceniach otrzymujemy:

$$\mathbb{P}(\hat{\beta}_1 + \text{se}(\hat{\beta}_1) t_{\frac{\alpha}{2}, n-k-1}^* \leq \beta_1 \leq \hat{\beta}_1 + \text{se}(\hat{\beta}_1) t_{1-\frac{\alpha}{2}, n-k-1}^*) = 1 - \alpha$$

- Rozkład *t* – studenta jest symetryczny, więc $|t_{\frac{\alpha}{2}, n-k-1}^*| = t_{1-\frac{\alpha}{2}, n-k-1}^*$

- Wtedy z prawdopodobieństwem 0.95:

$$\hat{\beta}_1 - \text{se}(\hat{\beta}_1) t_{1-\frac{\alpha}{2}, n-k-1}^* \leq \beta_1 \leq \hat{\beta}_1 + \text{se}(\hat{\beta}_1) t_{1-\frac{\alpha}{2}, n-k-1}^*$$

CO JEŻELI ε NIE MA ROZKŁADU NORMALNEGO?

- ▶ jeśli $\varepsilon \not\sim \mathcal{N}(0, \sigma^2)$ to wtedy statystyka T nie ma rozkładu t – *studenta* i nie możemy przeprowadzić testu
- ▶ Możemy skorzystać z własności asymptotycznych. Na podstawie Centralnego Twierdzenia Granicznego:

$$\frac{\hat{\beta}_1}{se(\hat{\beta}_1)} \xrightarrow{as.} \mathcal{N}(0, 1)$$

- ▶ nawet gdy składnik losowy nie ma rozkładu normalnego, nadal możemy przeprowadzić test jeśli mamy **wystarczająco dużą próbę**. Jednak wtedy odczytujemy wartości krytyczne ze standardowego rozkładu normalnego.

ROZKŁAD t – *studenta* $\longrightarrow \mathcal{N}(0, 1)$

TEST F

- ▶ Test F pozwala na przetestowanie wielu restrykcji (warunków), które chcemy nałożyć na model.
- ▶ Mamy dany model:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \varepsilon$$

- ▶ chcemy sprawdzić czy $\beta_1 = \beta_2 = 0$, zatem:

$$H_0 : \begin{cases} \beta_1 = 0 \\ \beta_2 = 0 \end{cases}$$

$$H_1 : \beta_1 \neq 0 \text{ lub } \beta_2 \neq 0$$

TEST F

- szacujemy model bez restrykcji (oznaczymy go literą U):

$$y = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 + e$$

- następnie szacujemy z restrykcjami (oznaczymy go literą R):

$$y = \hat{\beta}_0 + \hat{\beta}_3 x_3 + e$$

- budujemy statystykę testową:


$$F = \frac{(SSR_R - SSR_U) \frac{1}{q}}{SSR_U \frac{1}{n-k-1}} = \frac{(R_U^2 - R_R^2) \frac{1}{q}}{(1 - R_U^2) \frac{1}{n-k-1}} \sim F(1 - \alpha, q, n - k - 1)$$

gdzie q to liczba restrykcji

TEST F

- Korzystamy z rozkładu F z $(q, b - k - 1)$ stopniami swobody by wyznaczyć wartość krytyczną F^* . Przyjmujemy H_0 jeśli $F < F^*$
- Im większa różnica $R_U^2 - R_R^2 \Rightarrow$ tym wyższa statystyka $F \Rightarrow$ lepsze dopasowanie do danych dzięki dodaniu zmiennych

Obszary akceptacji i odrzucenia H_0 w teście F



TEST F ŁĄCZNEJ ISTOTNOŚCI

- Model bez restrykcji:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \dots + \beta_k x_k + \varepsilon$$

- Model z ograniczeniami ma postać:

$$y = \beta_0 + \varepsilon$$

- Hipoteza zerowa i alternatywna:

$$H_0 : \begin{cases} \beta_1 = 0 \\ \beta_2 = 0 \\ \vdots \\ \beta_k = 0 \end{cases}$$

H_1 : chociaż jeden parametr nie jest równy zero

TEST F ŁĄCZNEJ ISTOTNOŚCI

- ▶ budujemy statystykę testową opartą na SSE lub R^2 , pamiętając że w modelu tylko ze stałą $R^2 = 0$. Następnie szukamy wartości krytycznej korzystając z rozkładu $F(1 - \alpha, q, n - k - 1)$
- ▶ statystyka F oraz odpowiadające jej p -value są raportowane w pakietach statystycznych, np. w R.
- ▶ sprawdzamy czy nasz model jest lepszy niż model z tylko stałą

RESTRYKCJE W ZAPISIE MACIERZOWYM

- Hipotezy dotyczące kilku parametrów możemy zapisać w formie macierzowej:

$$\mathbf{H}\boldsymbol{\beta} = \mathbf{h}$$

gdzie \mathbf{H} to macierz $(q \times (k + 1))$ opisująca restrykcje, q to liczba restrykcji, \mathbf{h} to wektor stałych z każdej restrykcji.

- Przykład – test łącznej istotności:

$$\begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}_{q \times k+1} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix}_{k+1} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}_q$$

RESTRYKCJE W ZAPISIE MACIERZOWYM

► Przykład – test następujących restrykcji:

1. $\beta_1 = \beta_3$
2. $\beta_2 = a$
3. $\beta_1 + \beta_4 = b$

$$\begin{bmatrix} 0 & 1 & 0 & -1 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & -1 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{bmatrix} = \begin{bmatrix} 0 \\ a \\ b \end{bmatrix}$$

Pytania? Wątpliwości?
Dziękuję!

e: s.zalas@uw.edu.pl