

TESTY DIAGNOSTYCZNE

EKONOMETRIA WNE

Sebastian Zalas

University of Warsaw
s.zalas@uw.edu.pl

HETEROSKEDASTYCZNOŚĆ ε

- ▶ oznacza brak stałości wariancji. Jej obecność w modelu może prowadzić do błędnego wnioskowania statystycznego
- ▶ Można wykryć ją stosując test Breusha-Pagana albo test White'a. Hipoteza zerowa obu testów mówi o homoskedastyczności składnika losowego.
- ▶ Jeśli składnik losowy cechuje się heteroskedastycznością należy zastosować odporny estymator wariancji estymatora, np. estymator White'a.

UWZGLĘDNIENIE NIEISTOTNEJ ZMIENNEJ

- Przyjmijmy poniższą specyfikację modelu:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$

lecz tak naprawdę x_2 nie ma wpływu na y , wtedy $\beta_2 = 0$.

- Co się stanie gdy w regresji zostanie umieszczona zmienna x_2 ?

- nieobciążoność pozostaje nienaruszona: $\mathbb{E}[\hat{\beta}_2] = 0$

- wariancja $\mathbb{V}(\hat{\beta}_1) = \frac{\sigma^2}{(1-R_1^2) \sum_{i=1}^n (x_{i,1} - \bar{x}_1)^2}$

- wariancja estymatora $\tilde{\beta}_1$ bez uwzględniania x_2 :

$$\mathbb{V}(\tilde{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_{i,1} - \bar{x}_1)^2}$$

UWZGLĘDNIENIE NIEISTOTNEJ ZMIENNEJ

- ▶ Porównajmy wariancje: $V(\tilde{\beta}_1) < V(\hat{\beta}_1)$
- ▶ Usunięcie nieistotnych zmiennych powinno poprawić precyzję oszacowań
- ▶ **Uwaga!** Sama obserwacja, że zmienna jest (lub nie) istotna statystycznie, nie wystarczy, aby stwierdzić, że zmienna należy (lub nie należy) do modelu.
- ▶ Jeśli istnieją argumenty teoretyczne, zmienną należy zachować.

TEST RESET

- ▶ *Regression Specification Error Test* - test formy funkcyjnej

H_0 : liniowa postać modelu jest prawidłowa

H_1 : nieliniowa postać modelu jest prawidłowa

- ▶ Procedura testowa: szacujemy model i uzyskujemy z niego wartości dopasowane \hat{y} .

- ▶ Następnie szacujemy pomocniczy model w postaci:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \beta_{k+1} \hat{y}^2 + \beta_{k+2} \hat{y}^3 + \dots + \beta_{k+p} \hat{y}^p + v$$

Zwykle uwzględniamy \hat{y}^2 i \hat{y}^3

TEST RESET

- ▶ Testujemy następujące restrykcje:

$$\beta_{k+1} = \beta_{k+2} = \dots = \beta_{k+p} = 0$$

korzystając z statystyki F która ma rozkład $F(1 - \alpha, p, n - k - 1)$

- ▶ Odrzucenie H_0 wskazuje na to, że liniowa forma modelu nie jest poprawna \Rightarrow problem z założeniem KMRL o liniowości modelu
- ▶ Należy spróbować włączyć do modelu czynniki uwzględniające nieliniową zależność

WSPÓŁLINIOWOŚĆ

- ▶ Współliniowość deterministyczna - występuje gdy jedna ze zm. objaśniających jest kombinacją liniową innych zmiennych objaśniających
- ▶ Np.: x_1 oraz $x_2 = 2 \times x_1 \Rightarrow \hat{\beta}^{MNK}$ jest niezdefiniowany, ponieważ $\text{rz}(\mathbf{X}^T \mathbf{X})$ nie jest pełny
- ▶ Współliniowość stochastyczna pojawia się gdy występuje silna korelacja między dwiema zmiennymi objaśniającymi.

WSPÓŁLINIOWOŚĆ

Objawy współliniowości:

- ▶ małe zmiany w danych powodują duże wahania oszacowań
- ▶ Oszacowania mogą mieć wysokie błędy standardowe i niskie poziom istotności, nawet gdy cały model jest istotny statystycznie a R^2 jest wysoki
- ▶ Współczynniki mogą mieć nieintuicyjny znak lub nieracjonalną wielkość

WSPÓŁLINIOWOŚĆ

- Szacujemy model $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$

- Wariancja estymatora $\hat{\beta}_1$

$$\mathbb{V}(\hat{\beta}_1) = \frac{\sigma^2}{(1 - R_1^2) \sum_{i=1}^n (x_{i,1} - \bar{x}_1)^2}$$

gdzie R_1^2 to R^2 z regresji $x_1 \sim x_2$

- Im silniej x_1 i x_2 są skorelowane to $\mathbb{V}(\hat{\beta}_1)$ rośnie

WSPÓŁLINIOWOŚĆ

- ▶ Do wykrywania współliniowości służy wskaźnik inflacji wariancji, VIF:

$$VIF_i = \frac{1}{1 - R_i^2}$$

$VIF_i > 10$ sugeruje istnienie silniej współliniowości.

- ▶ Można sprawdzić korelację między zmiennymi objaśniającymi.
- ▶ Współliniowość w modelu można zmniejszyć poprzez np. usunięcie zmiennej z wysokim VIF.

TEST NORMALNOŚCI SKŁADNIKA LOSOWEGO

- ▶ W KMRL składnik losowy ma rozkład normalny. Jeśli tak nie jest, wnioskowanie statystyczne może być błędne.
- ▶ Aby przetestować to założenie stosujemy test Jarque-Bery. W istocie sprawdza, czy dane mają skośność (S) i kurtozę (K) pasujące do rozkładu normalnego.

$$S = \frac{\hat{\mu}_3}{\hat{\sigma}^3} = \frac{\frac{1}{n} \sum (x_i - \bar{x}_i)^3}{\left(\frac{1}{n} \sum (x_i - \bar{x}_i)^2\right)^{\frac{3}{2}}}$$
$$K = \frac{\hat{\mu}_4}{\hat{\sigma}^4} = \frac{\frac{1}{n} \sum (x_i - \bar{x}_i)^4}{\left(\frac{1}{n} \sum (x_i - \bar{x}_i)^2\right)^2}$$

TEST NORMALNOŚCI SKŁADNIKA LOSOWEGO

- Hipoteza zerowa:

$$H_0 : \begin{cases} S = 0 \\ K = 3 \end{cases}$$

jeśli jest prawdziwa, składnik losowy ma rozkład normalny.

- Statystyka testowa:

$$JB = \frac{n}{6} \left(S + \frac{1}{4}(K - 3)^2 \right) \sim \chi_n^2$$

ma rozkład chi kwadrat z n stopniami swobody

- Odrzucenie H_0 może wskazywać na niespełnienie założenia o normalności składnika losowego. Stanowi to problem w małych próbach.

OBSERWACJE NIETYPOWE

- ▶ Jakie obserwacje są nietypowe?
 - takie, które odznaczają się dużą różnicą między danymi a wartościami dopasowanymi
 - takie, które silnie różnią się od pozostałych obserwacji
- ▶ Warto sprawdzić czy zaburzą oszacowanie modelu:
 - dźwignia, standaryzowane reszty, dystans Cook'a
- ▶ Co zrobić?:
 - obserwacje błędne - wyrzucić
 - obserwacje nietypowe - sprawdzić skąd się wzięły; sprawdzić, czy oszacowania są bardzo wrażliwe na nie
 - zastosowanie logarytmów będzie zmniejszyło wpływ obserwacji odstających
 - można również przyciąć rozkłady zmiennych po np. 1% z obu stron

STABILNOŚĆ PARAMETRÓW - TEST CHOW'A

- Specyfikując model zakładamy, że jego założenia są spełnione dla wszystkich obserwacji.
- Możemy sprawdzić czy parametry są stabilne w całej próbie, czyli czy nie różnią się w podpróbach.
- Szacujemy modele na podpróbach i testujemy czy ich parametry są takie same:

$$H_0 : \beta_1 = \beta_2$$

$$H_1 : \beta_1 \neq \beta_2$$

gdzie β_1 i β_2 to wektory parametrów modeli dla dwóch podprób.

STABILNOŚĆ PARAMETRÓW - TEST CHOW'A

- Statystyka testowa:

$$F = \frac{\frac{RSS - RSS_1 - RSS_2}{k+1}}{\frac{RSS_1 + RSS_2}{n - 2(k+1)}} \sim F(k+1, n - 2(k+1))$$

gdzie:

- RSS - suma kwadratów reszt modelu szacowanego na całej próbie
 - RSS_1 - suma kwadratów reszt modelu szacowanego na podpróbie #1
 - RSS_2 - suma kwadratów reszt modelu szacowanego na podpróbie #2
- Jeśli H_0 zostanie odrzucona, należy rozważyć np.: oszacowanie modeli na podpróbach lub dołączenie do modelu odpowiedniej zm. binarnej.

Pytania? Wątpliwości?
Dziękuję!

e: s.zalas@uw.edu.pl